Ejercicio 2.4 - Análisis de las 5 topologias

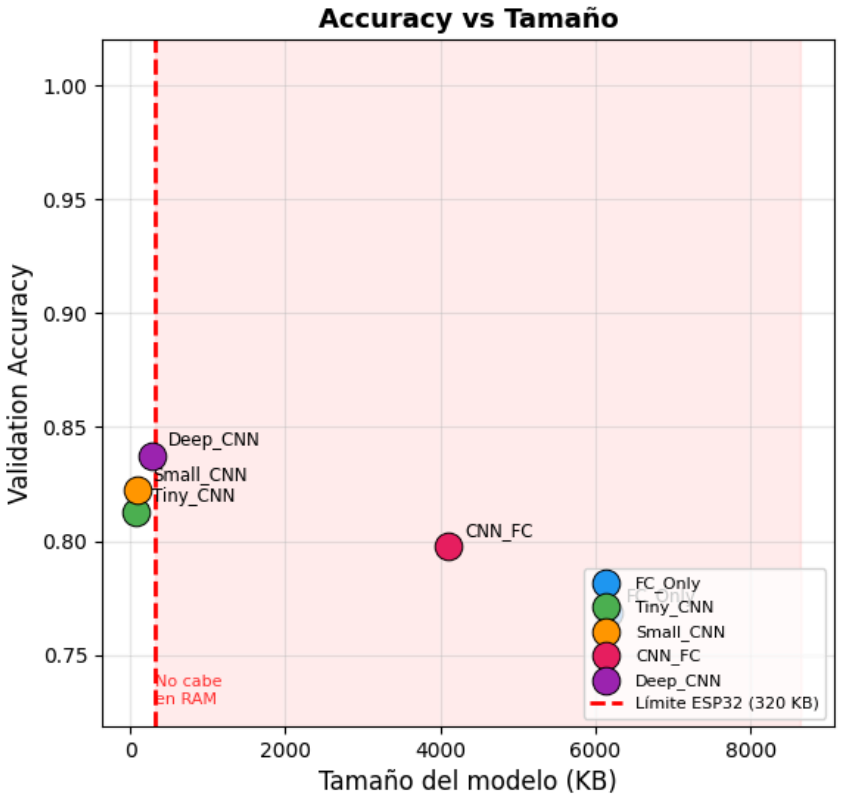

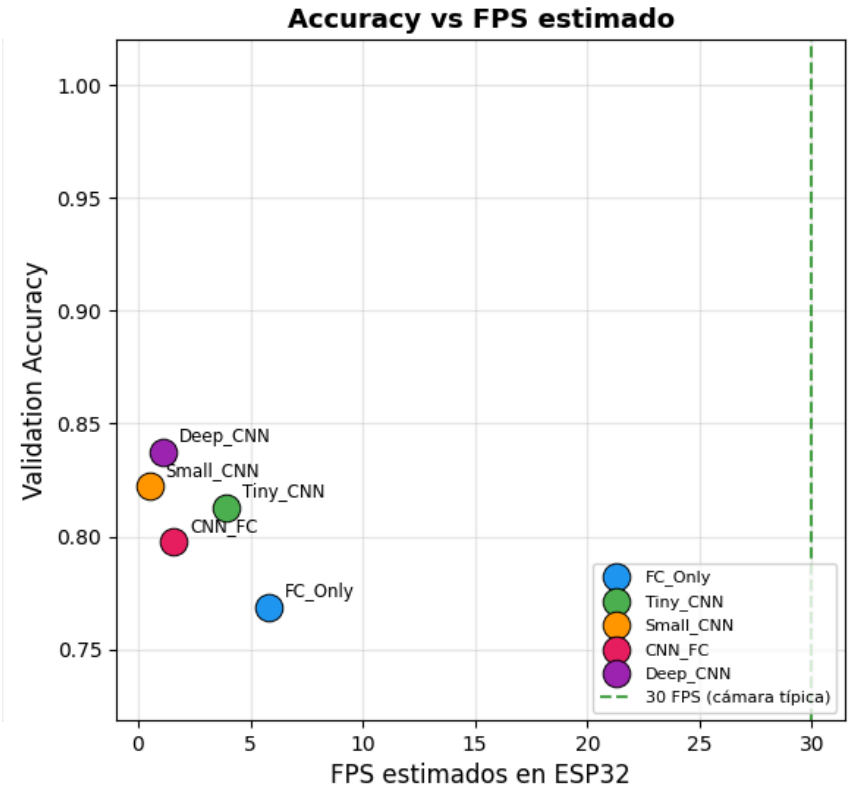

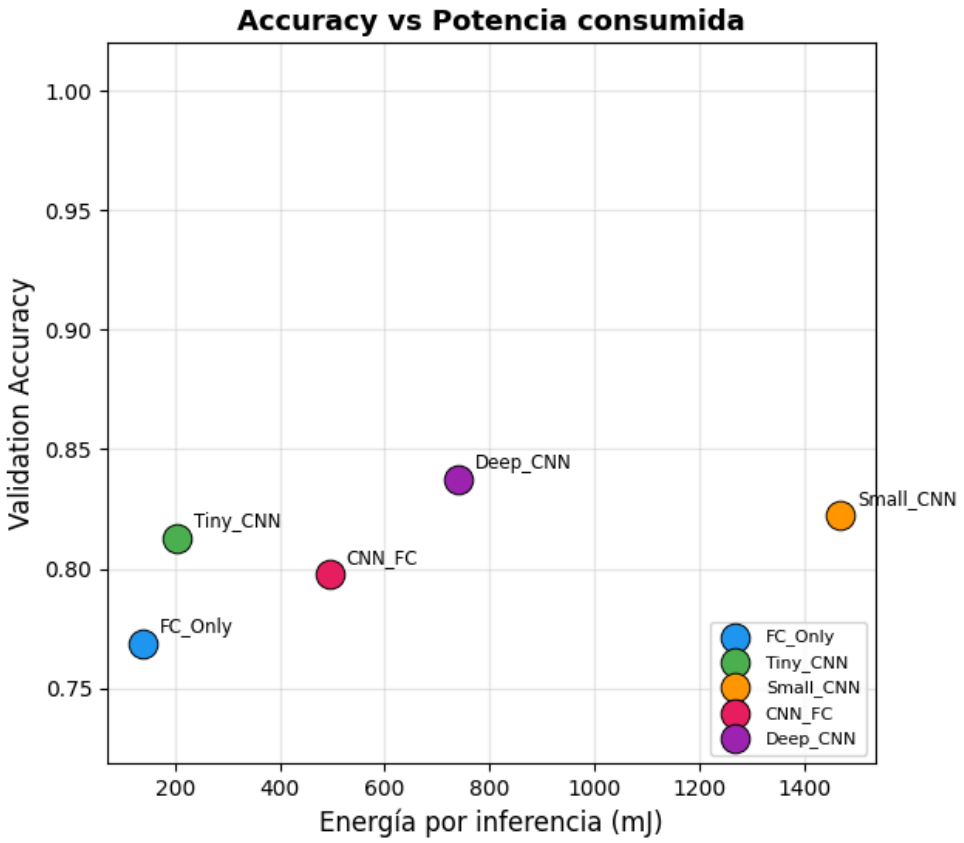
Accuracy vs Potencia consumida
Validation Accuracy
Energía por inferencia (mJ)
1.00
0.95
0.90
0.85
0.80
0.75
200
400
600
800
1000
1200
1400
Deep_CNN
Small_CNN
Tiny_CNN
CNN_FC
FC_Only
FC_Only
Tiny_CNN
Small_CNN
CNN_FC
Deep_CNN

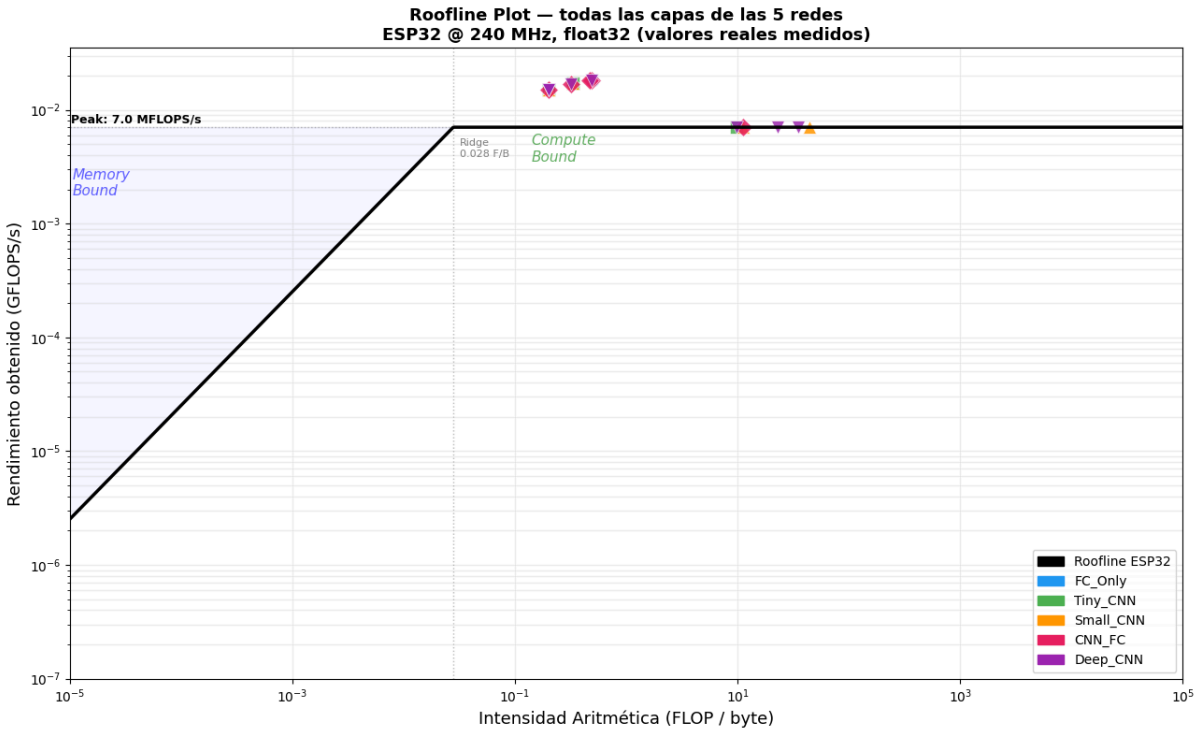
Roofline Plot — todas las capas de las 5 redes
ESP32 @ 240 MHz, float32 (valores reales medidos)
Peak: 7.0 MFLOPS/s
Memory Bound
Ridge 0.028 F/B
Compute Bound
Rendimiento obtenido (GFLOPS/s)
Intensidad Aritmética (FLOP / byte)
Roofline ESP32
FC_Only
Tiny_CNN
Small_CNN
CNN_FC
Deep_CNN

Análisis

A partir de las cinco topologías evaluadas, se consideraron tres criterios: que el modelo quepa en la RAM del ESP32 (320 KB), que logre buena accuracy y que tenga un consumo energético razonable. Los modelos FC_Only y CNN_FC se descartan de inmediato por exceder la memoria (6177 KB y 4106 KB). Entre los restantes, Deep_CNN aparece como la mejor opción: alcanza una accuracy de 0.8374, tiene un tamaño de 279.9 KB (dentro del límite) y un consumo de 740 mJ por inferencia. Aunque es menos eficiente que Tiny_CNN (203 mJ), esto se explica por su mayor capacidad representacional.

Si bien no llega a los 30 FPS de una cámara típica (opera a 1.1 FPS), esto no es crítico para detectar el identificador de un robot sumo, donde no se requiere procesamiento continuo sino detecciones confiables en momentos puntuales. Además, el análisis Roofline muestra que sus capas operan en régimen compute-bound, lo que indica un uso eficiente del hardware: el límite está en el cómputo disponible y no en la memoria.